

Filière : Sciences Géomatiques et Ingénierie Topographique

L'urbanisme alternatif : L'expansion urbaine sur la mer

***Cas d'étude Palm Jumeirah, Dubaï, UAE.
2001-2017***

Encadré par :

Pr. I. SEBARI

Rédigé et présenté par :

Ait BenBouchaib Oumaima.....N°3

Benlahcen Wiame N°11

El Imami AyoubN°24

Mastari WijdaneN°47

Remerciement

*Avant de commencer ce rapport, on remercie toutes les personnes qui ont rendu ce travail possible. On tient à exprimer nos sincères gratitude au professeur **Imane Sebari** pour son travail acharné et ses informations précieuses qui nous ont permis d'approfondir nos connaissances dans le domaine de la télédétection.*

Résumé

Depuis toujours, l'expansion urbaine s'est souvent réalisée au détriment des terres agricoles, représentant une pression constante sur le sol.

Cependant, au cours des dernières décennies, une nouvelle tendance a émergé, marquée par l'avènement de villes construites sur l'eau représentant un changement significatif dans les schémas traditionnels d'implantation urbaine.

Dans ce sujet, on va prendre comme exemple "Palm Jumeirah", dont on étudiera l'évolution entre 2001 et 2017, en se basant sur l'analyse de données provenant d'images satellitaires. En se concentrant sur cinq méthodes de classification d'images, le document examine la classification basée pixel, la classification basée objet avec arbres de décision et règles, les Random Forests, et la classification par réseau de neurones.

Chacune de ces méthodes est évaluée quant à sa capacité à détailler les changements dans le paysage urbain, mettant l'accent sur l'expansion maritime du "Palm Jumeirah". Dans ce travail, nous visons à fournir des informations approfondies sur les forces et les faiblesses de chaque approche, ainsi que sur leur applicabilité à l'analyse de l'évolution urbaine.

En résumé, le rapport constitue une ressource complète visant à éclairer l'expansion urbaine maritime du "Palm Jumeirah" au fil du temps, en utilisant des techniques avancées de traitement d'images. Les résultats sont présentés de manière pratique à travers un géoportail, offrant ainsi une perspective tangible sur l'évolution urbaine dans cette région spécifique.

Mots clés : classification basée pixel, classification basée objet, arbres de décision, à base de règles, les Random Forests, classification par réseau de neurones.

Abstract

Historically, urban expansion has often occurred at the expense of agricultural land, representing a constant pressure on the soil. However, in recent decades, a new trend has emerged, marked by the rise of cities built on water, signifying a significant shift in traditional urban planning patterns.

In this context, we will take "Palm Jumeirah" as an example, studying its evolution between 2001 and 2017 based on the analysis of data from satellite images. Focusing on five image classification methods, the document examines pixel-based classification, object-based classification with decision trees and rules, Random Forests, and neural network-based classification.

Each of these methods is evaluated for its ability to detail changes in the urban landscape, with an emphasis on the maritime expansion of "Palm Jumeirah." In this work, we aim to provide in-depth insights into the strengths and weaknesses of each approach, as well as their applicability to the analysis of urban evolution.

In summary, the report constitutes a comprehensive resource aiming to shed light on the maritime urban expansion of "Palm Jumeirah" over time, using advanced image processing techniques. The results are presented practically through a geoportal, offering a tangible perspective on urban evolution in this specific region.

Keywords: pixel-based classification, object-based classification, decision trees, rule-based, Random Forests, neural network classification.

Table des matières

I.	Introduction :	8
II.	Présentation de la thématique :	10
III.	Objectif du travail :	11
IV.	Bibliographie :	12
1.	Segmentation :	12
2.	Classification :	12
2.1.	Méthode Plus Proches Voisins :	12
2.2.	Méthode Arbre de Décision :	13
2.3.	Les systèmes à base de règles :	13
2.4.	Méthode de classification par réseau de neurones :	14
V.	Méthodologie :	15
VI.	Méthodes de classification :	16
1.	Classification Plus proche voisin basée pixel :	16
1.1.	Logiciel utilisé :	16
1.2.	Zones d'entraînement :	16
1.3.	Résultat et analyses :	17
2.	Classification basée objet : Plus proches voisins , arbre de décision et basée règles:	18
2.1.	Logiciel utilisé :	18
2.2.	Procédure :	18
2.3.	Classification par Random Forest :	22
2.4.	Classification par réseau de neurones :	23
2.4.1.	Logiciel utilisé : ENVI :	24
2.4.2.	Définition des régions d'intérêt :	24
2.4.3.	Choix des paramètres :	25
2.4.4.	Matrice de confusion :	34
VII.	Comparaison entre les différentes méthodes:	40
1.	Les méthodes basées pixel :	40
2.	Les méthodes basées objet :	41
3.	Réseau de neurones :	42
4.	Détection du changement :	45
5.	Présentation du site web :	46
6.	Conclusion :	47

Liste des figures :

Figure 1 : Placement des pixels de chaque classe (Classe 1 : Eau, Classe 2 : Végétation, Classe 3 : Bâti.) dans l'espace représenté par les bandes Bleu et PIR (A). Calcul des barycentres de chaque classe (B).	12
Figure 2 : Schéma de la structure de l'arbre de décision	13
Figure 3 : représentation schématique d'un neurone artificiel	14
Figure 4 : eprésentation schématique de la méthodologie de travail	15
Figure 5 : choix des zones d'entraînement pour chacune des classes.	16
Figure 6 : Résultats de la méthode Plus Proche Voisin basée pixel	17
Figure 7 : Métriques de plus proche voisin basée pixel	17
Figure 8 : Les zones d'entraînement	19
Figure 9 : Résultats de la classification par plus proche voisin basée objet	19
Figure 10 : Les conditions de l'image 2001	19
Figure 11 : Les conditions de l'image 2017	20
Figure 12 : Résultats par la méthode Arbre de décision	20
Figure 13 : Les conditions sur les classes	21
Figure 14 : Résultat de Système à base de règles	22
Figure 15 : Résultat de Système à base de règles	23
Figure 16 : Matrice de confusion Random Forest pour 2001 et 2017	23
Figure 17 : Zones d'entrainement pour l'image de 2001	24
Figure 18 : Zones d'entrainement pour l'image de 2017	25
Figure 19 : Paramètres identifiés lors du 1er essai	26
Figure 20 : Graphe représentant le RMS d'entrainement en fonction du nombre d'itérations	26
Figure 21 : Résultats de la classification par réseau de neurones de l'image de 2001	27
Figure 22 : Résultats de la classification par réseau de neurones de l'image de 2001 après modification de ROIs	27
Figure 23 : Graphe représentant le RMS d'entrainement en fonction du nombre d'itérations	28
Figure 24 : Paramètres identifiés lors du 2ème essai	28
Figure 25 : Résultats de la classification par réseau de neurones de l'image de 2001 lors du 2ème essai	28
Figure 26 : Graphe représentant le RMS d'entrainement en fonction du nombre d'itérations	29
Figure 27 : Résultats de la classification par réseau de neurones de l'image de 2001 lors du 3ème essai	29
Figure 28 : Paramètres identifiés lors du 1er essai image 2017	30
Figure 29 : Graphe représentant le RMS d'entrainement en fonction du nombre d'itérations	30
Figure 30 : Résultats de la classification par réseau de neurones de l'image de 2017 lors du 1er essai	31
Figure 31 : Paramètres identifiés lors du 2ème essai image 2017	31
Figure 32 : Graphe représentant le RMS d'entrainement en fonction du nombre d'itérations Essai2	32

Figure 33 : Résultats de la classification par réseau de neurones de l'image de 2017 lors du 2ème essai	32
Figure 34 : Graphe représentant le RMS d'entraînement en fonction du nombre d'itérations Essai2	33
Figure 35 : Résultats de la classification par réseau de neurones de l'image de 2017 lors du 3ème essai	33
Figure 36 : Matrice de confusion 1er essai.....	34
Figure 37 : Matrice de confusion 1er essai après changement.....	35
Figure 38 : Matrice de confusion 2ème essai	35
Figure 39 : Matrice de confusion 3ème essai	36
Figure 40 : Matrice de confusion 1er essai.....	37
Figure 41 : Matrice de confusion 2ème essai	38
Figure 42 : Matrice de confusion 3ème essai	39
Figure 43 : Résultat de classification pour l'image de 2001	43
Figure 44 : Résultat de classification pour l'image de 2017 par RN.....	44
Figure 45 : Carte de détection du changement.....	45
Figure 46 : Site Web	46
Figure 47 : Les limites de la zone de Rabat	47

I. Introduction :

L'évolution rapide de la technologie de l'imagerie a engendré une profusion de données visuelles, donnant naissance à une ère où l'analyse et la compréhension des images sont devenues cruciales. Dans cette ère numérique, le traitement d'images avancé se positionne comme une discipline clé, jouant un rôle central dans l'exploitation des informations visuelles à travers divers domaines tels que la télédétection, la médecine, l'industrie manufacturière, et bien d'autres.

Le cœur de ce paradigme émerge dans la classification d'images, une entreprise complexe consistant à attribuer des étiquettes ou des catégories aux pixels, aux objets ou aux scènes dans une image. Cette tâche, bien que fondamentale, présente des défis considérables en raison de la variabilité des données, de la complexité des scénarios et des exigences croissantes en matière de précision.

Notre rapport se concentre sur une étude comparative des méthodes de classification d'images, une démarche visant à éclairer les choix et les compromis inhérents à chaque approche, pour cela, nous détaillerons cinq méthodes distinctes:

La première de ces méthodes, la classification basée pixel, plonge dans l'analyse minutieuse de chaque pixel, considérant ses caractéristiques individuelles pour construire une représentation globale de l'image. Cette approche, bien que conceptuellement simple, révèle sa puissance dans la capacité à traiter des informations détaillées au niveau le plus fondamental de l'image.

Poursuivant notre exploration, la classification basée objet introduit une dimension supplémentaire en considérant la relation spatiale entre les pixels, formant ainsi des objets significatifs. L'utilisation d'arbres de décision et de règles dans cette approche amplifie la capacité du système à prendre des décisions complexes basées sur des critères prédéfinis.

Les Random Forests, une méthode d'ensemble basée sur des arbres de décision, apportent une sophistication supplémentaire en agrégeant les résultats de multiples arbres pour améliorer la robustesse du modèle.

Enfin, notre étude aborde la classification par réseau de neurones, une approche bio-inspirée qui simule le fonctionnement du cerveau humain pour reconnaître des modèles complexes. Cette méthode, bien que souvent exigeante en termes de données et de puissance de calcul, ouvre des opportunités passionnantes pour la classification d'images dans des contextes hautement complexes.

Au-delà de l'examen détaillé de ces méthodes, notre rapport propose une application concrète de ces concepts dans la conception d'un géoportail. Ce dernier servira de Géoportail pour visualiser et interagir avec les résultats de nos expérimentations, illustrant ainsi la pertinence pratique de ces méthodes dans un contexte du monde réel.

En somme, ce rapport se veut une plongée approfondie dans le paysage complexe de la classification d'images avancée, offrant une compréhension détaillée des forces et des faiblesses de chaque méthode. Ce faisant, nous espérons contribuer à l'avancement continu de ce domaine crucial.

II. Présentation de la thématique :

L'expansion urbaine était depuis toujours aux dépends du sol et plus précisément aux dépends des terres agricoles.

Mais ces dernières décennies on a assisté à la naissance d'une nouvelle forme d'implantation urbaine : les villes sur l'eau , appelée aussi l'urbanisme alternatif. Les exemples de cette expansion urbaine sur l'eau sont très nombreux, dans ce rapport on a choisi " Palm Jumeirah " comme cas d'étude.

Situé sur la côte de Dubaï, le Palmier Jumeirah est l'une des attractions touristiques les plus célèbres de Dubaï. Il s'agit d'un ensemble d'îles artificielles en forme de palmier composé d'un tronc, 17 feuilles et d'un demi-cercle qui sert de digue.

La construction du palmier a commencé en 2001 et a été finalisée en 2008. Pour cela, du sable et des roches ont été utilisés pour former un mur de six mètres de haut et d'une superficie totale de 31 kilomètres carrés.



III. Objectif du travail

Ce travail vise à :

- Appliquer des méthodes de traitement d'images avancées en se basant sur des données provenant d'images satellitaires pour obtenir une représentation précise et détaillée des évolutions du site au fil du temps.
- Examiner et comparer cinq approches distinctes de classification d'images, à savoir la classification basée pixel, la classification basée objet avec arbres de décision et règles, les Random Forests, et la classification par réseau de neurones.
- Faire une comparaison entre les différentes méthodes de classification, permettant ainsi de comprendre les scénarios dans lesquels chaque approche excelle.
- Analyser et comprendre les changements dans le paysage urbain, en mettant particulièrement l'accent sur l'expansion maritime de "Palm Jumeirah" entre les années 2001 et 2017.
- Proposer un site web comme application pratique, offrant une plateforme conviviale pour visualiser, interagir et interpréter les résultats des expérimentations, afin de renforcer la pertinence des méthodes dans des situations du monde réel.

IV. Bibliographie :

1. Segmentation :

La segmentation d'images est un traitement de bas niveau. Elle constitue la première étape dans plusieurs processus d'analyse d'image (extraction, reconnaissance d'objets, classification, etc.). Elle l'est dans le cas de l'approche basée objets. Elle permet la création des objets image. La qualité de la segmentation détermine le succès ou l'échec de toutes les procédures d'analyse subséquentes.[1]

2. Classification :

2.1. Méthode Plus Proches Voisins :

C'est l'algorithme le plus facile à appréhender et à mettre en place. Il est largement répandu dans le monde de la télédétection, bien que maintenant des techniques plus poussées soient plus communément employées.

Comme pour tout processus de classification supervisée, cette technique repose sur une digitalisation manuelle de *régions d'entraînement*.

Pour chaque zone d'entraînement, les valeurs des pixels sous-jacents sont relevées, les moyennes sont calculées, et chaque classe est ainsi caractérisée par une signature radiométrique. L'idée est ensuite d'associer à chaque pixel de l'image qui n'a pas servi comme zone d'entraînement la classe qui lui est le plus proche d'un point de vue radiométrique.

Une fois les polygones d'entraînement créés, l'algorithme calcule les valeurs de réflectances moyennes dans chaque bande spectrale. Un barycentre est ainsi calculé pour chaque classe. Nous détaillons sur la figure suivante le principe de construction de ce barycentre en prenant en compte seulement la bande du *Bleu* et du *PIR* pour des raisons de représentation (Fig).

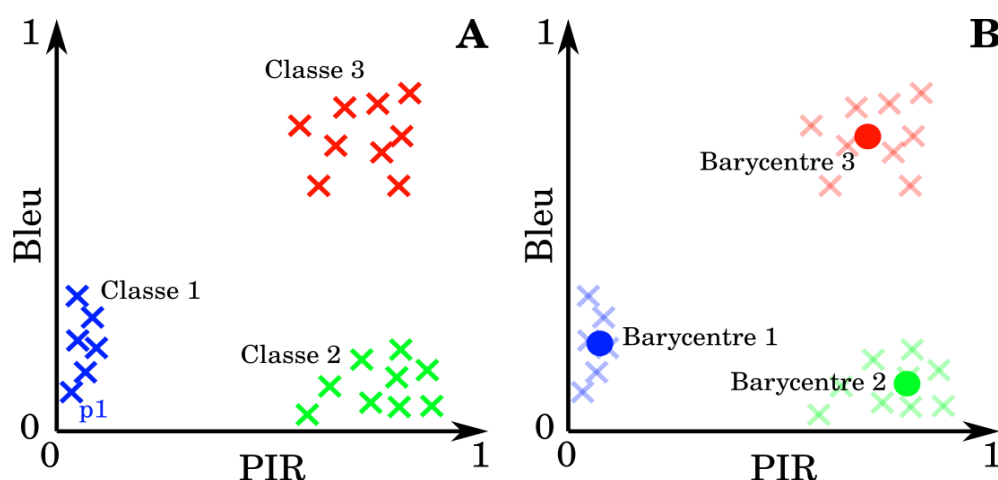


Figure 1 : Placement des pixels de chaque classe (Classe 1 : Eau, Classe 2 : Végétation, Classe 3 : Bâti.) dans l'espace représenté par les bandes Bleu et PIR (A). Calcul des barycentres de chaque classe (B).

Le but est de calculer les distances séparant ce pixel à chacun des barycentres. Une fois toutes les distances calculées, le pixel P est attribué à la classe dont le barycentre est le plus proche. C'est-à-dire à la classe pour laquelle la distance est minimale.[2]

2.2. Méthode Arbre de Décision

L'arbre de décision a une structure hiérarchique, une structure arborescente, qui se compose d'un nœud racine, de branches, de nœuds internes et de nœuds feuille.[3]

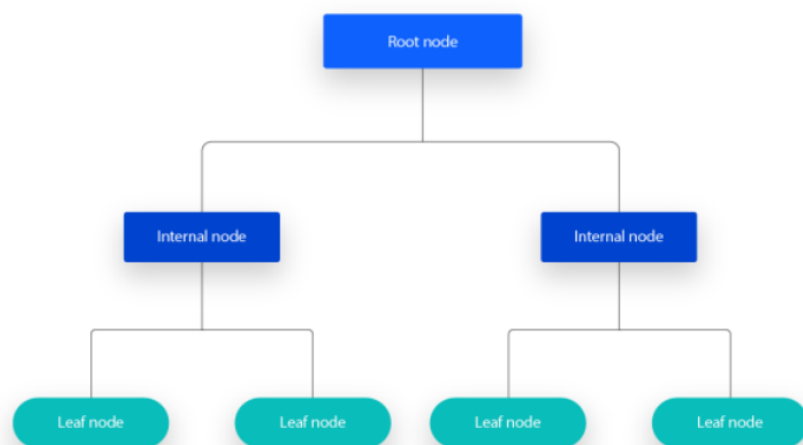


Figure 2 : Schéma de la structure de l'arbre de décision

D'une manière générale, l'arbre de décision fonctionne selon un principe de partitionnement récursif. L'objectif du partitionnement est de créer des groupes d'individus les plus homogènes possible par rapport à la variable que l'arbre cherche à classer. Pour y parvenir, l'algorithme à l'origine de la construction ou « pousse » de l'arbre pose une succession de questions binaires (oui/non) relatives aux variables qui auront été définies comme des variables explicatives. Ce sont les réponses à ces questions qui constituent les branches de l'arbre. [4]


2.3. Les systèmes à base de règles

Les systèmes à base de règles entrent dans le domaine des systèmes experts. Ils traduisent la connaissance par des règles de décision. Une règle indique quelle(s) action(s) à entreprendre ou quelle(s) conclusion(s) à tirer face à une situation donnée. Elle est souvent sous la forme : Si condition(s) Alors action(s) Ainsi, une classe d'objets peut être décrite par une ou plusieurs règles. Chaque règle peut intégrer un ou plusieurs types d'informations (spectral, géométrique, contextuel, etc.). La réponse à une règle de décision est donnée généralement avec un degré. Les méthodes de classification à base de règles nécessitent des règles efficaces pour la prise de décision. La formulation des règles à partir de la connaissance des experts n'est pas toujours évidente. La détermination des seuils des règles et d'éventuels poids est laissée en général à l'expérience de l'opérateur. [1]

2.4. Méthode de classification par réseau de neurones :

2.4.1. Définition de neurone artificielle

Le neurone formel ou artificiel est un processeur imitant grossièrement la structure d'un neurone biologique. Il contient plusieurs entrées et une sortie. Chaque entrée E_i est pondérée par un poids P_{ki} . La fonction de sommation est appliquée pour produire S_k . La fonction d'activation N est appliquée ensuite sur S_k . La figure 3 montre le modèle classique d'un neurone artificiel. [5]



Avec :

- E_i : entrées du neurone (pixels d'entraînements dans notre cas)
- P_{ki} : poids synaptique
- Σ : activation du neurone
- Y_k : sortie du neurone (pixels classifié)
- S_k : fonction de sortie

Figure 3 : représentation schématique d'un neurone artificiel

2.4.2. Définition de réseau de neurones artificielles

Les réseaux de neurones artificiels sont des réseaux fortement connectés de processeurs élémentaires fonctionnant en parallèle. Chaque processeur élémentaire calcule une sortie unique sur la base des informations qu'il reçoit. Toute structure hiérarchique de réseaux est évidemment un réseau. Les réseaux de neurones artificiels sont des réseaux fortement connectés de processeurs élémentaires fonctionnant en parallèle. Chaque processeur élémentaire calcule une sortie unique sur la base des informations qu'il reçoit. Toute structure hiérarchique de réseaux est évidemment un réseau. [6]

V. Méthodologie :

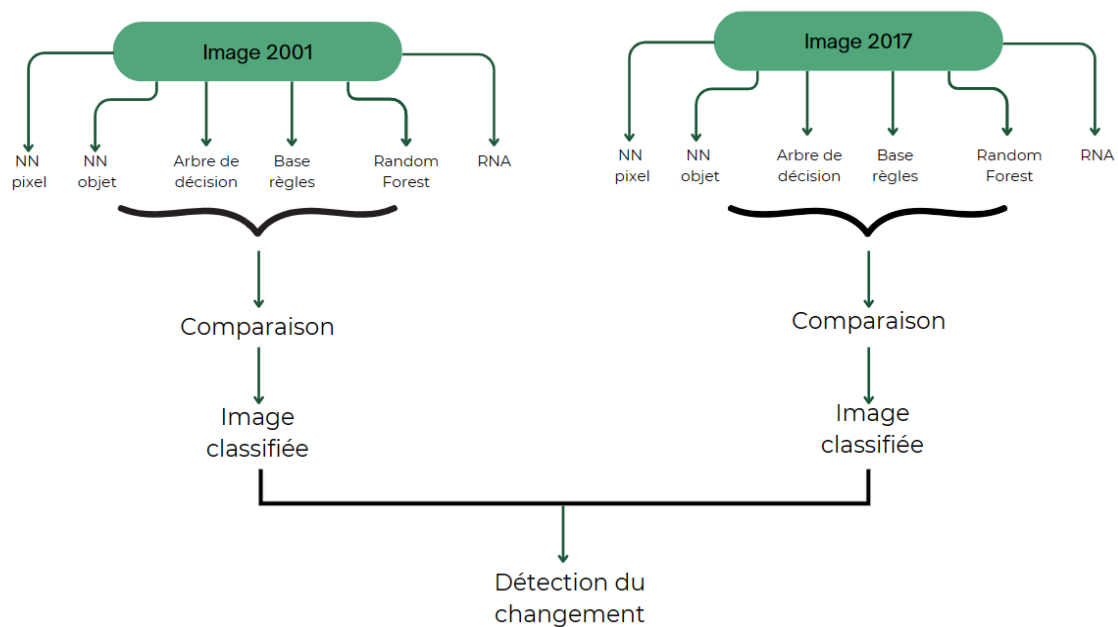


Figure 4 : représentation schématique de la méthodologie de travail

VI. Méthodes de classification :

1. Classification Plus proche voisin basée pixel :

1.1. Logiciel utilisé :

Erdas Imagine

Erdas Imagine est un logiciel de télédétection permettant de visualiser, gérer et extraire des informations à partir de raster (images aériennes, satellites). Très simple à appréhender, ERDAS permettra, en complément de votre SIG, de prendre toute décision utile sur votre territoire d'étude (cartographie de ressource, contexte d'urgence, étude prospective).

1.2. Zones d'entraînement :

Avant de commencer notre classification, on a premièrement fixé les classes qu'on souhaite obtenir. Pour notre thématique, on a choisi les classes suivantes : Végétation, Eau, Bâtiment, Route et Sol Nu.

Après on a introduit les différentes zones d'entraînement correspondantes pour chaque classe.

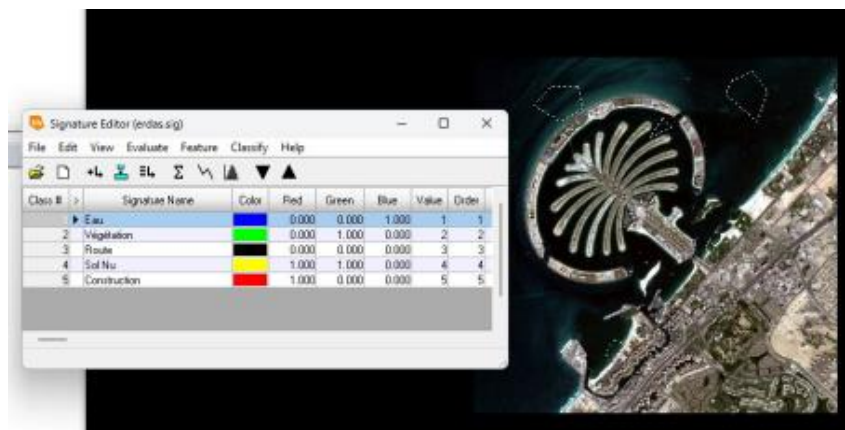


Figure 5 : choix des zones d'entraînement pour chacune des classes.

1.3. Résultat et analyses :

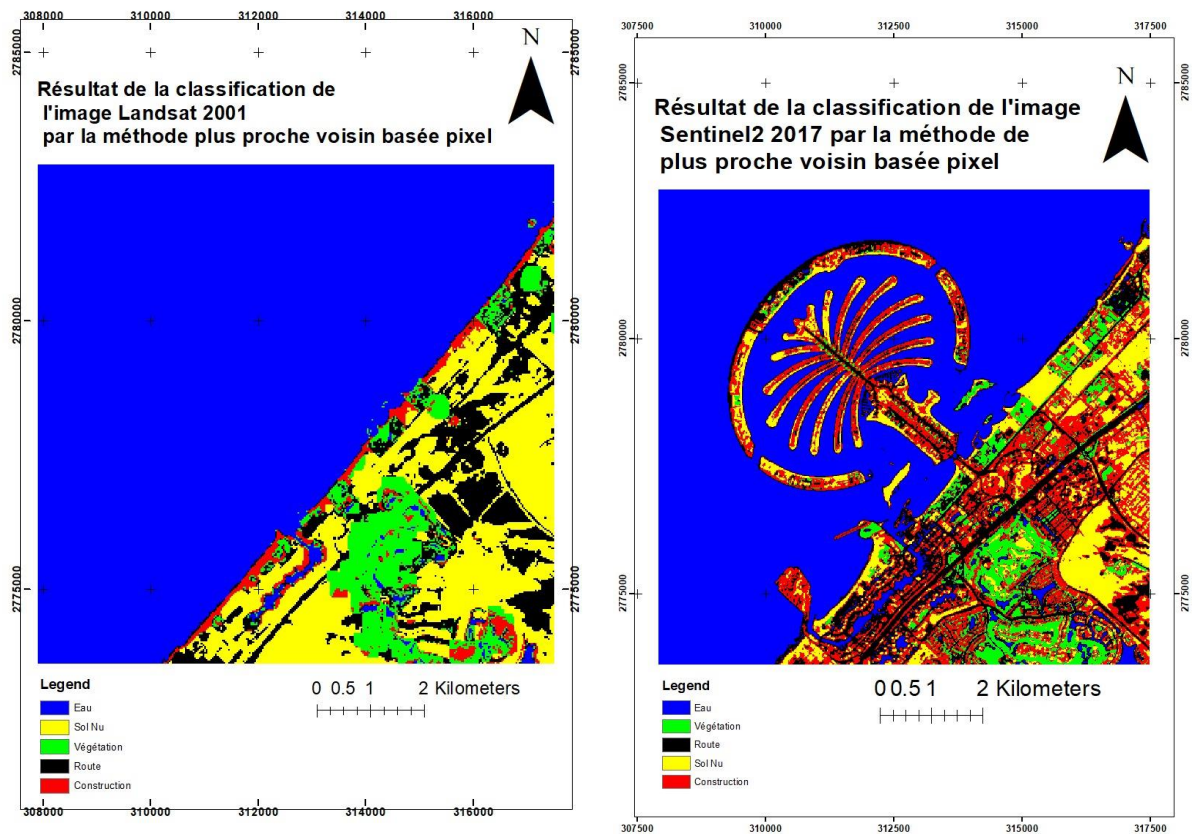


Figure 6 : Résultats de la méthode Plus Proche Voisin basée pixel

On peut voir clairement que la classification n'est pas parfaite puisqu'on a des fausses détections surtout pour la classe "Route", "Bâtiment" et "Sol Nu". En se basant sur les métriques, on peut constater la même chose.

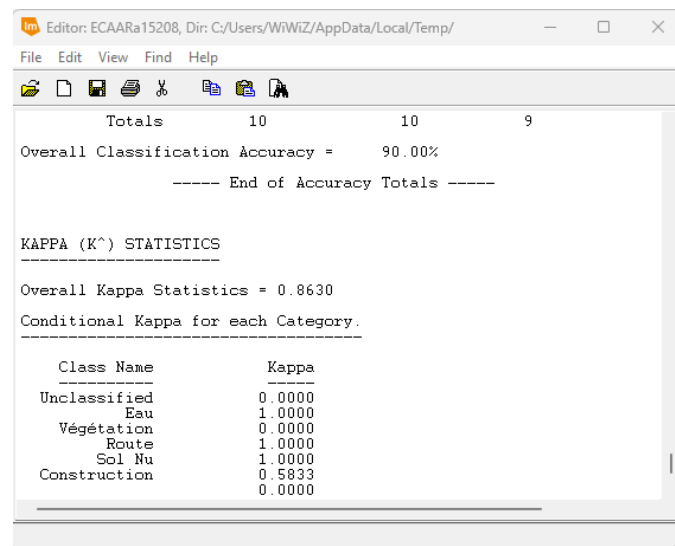


Figure 7 : Métriques de plus proche voisin basée pixel

2. Classification basée objet : Plus proches voisins , arbre de décision et basée règles:

2.1. Logiciel utilisé :

eCognition:

Le logiciel eCognition fonctionne d'une manière un peu différente de la plupart des logiciels sur le marché qui permettent de faire de la classification. Au lieu de travailler au niveau pixel, c'est-à-dire utiliser les pixels comme objets fondamentaux de classification, eCognition génère d'abord ses propres objets, appelés « image objects », par un procédé de segmentation paramétrable. Ensuite ces objets sont classifiés en utilisant une des techniques disponibles dans le logiciel. La figure 1 présente la procédure suivie par ce logiciel.[7]

2.2. Procédure :

Avant d'entamer la classification, on doit d'abord faire une segmentation puisqu'on travaille avec une approche basée objet. Pour cela, on a fait plusieurs tests sur le seuil de segmentation et on a finalement fixé $L=30$ pour l'image Sentinel 2 (2017) et $L=5$ pour l'image Landsat (2001).

Après la phase de segmentation, on va passer à la classification, pour cette étape on a travaillé avec 3 méthodes différentes :

Plus Proche Voisin :

Dans un premier temps, on a créé les 5 classes dans "Class Hierarchy", puis on a déterminé les zones d'entraînement de chaque classe





Figure 8 : Les zones d'entraînement

Après on a lancé la classification et on a obtenu le résultat suivant :

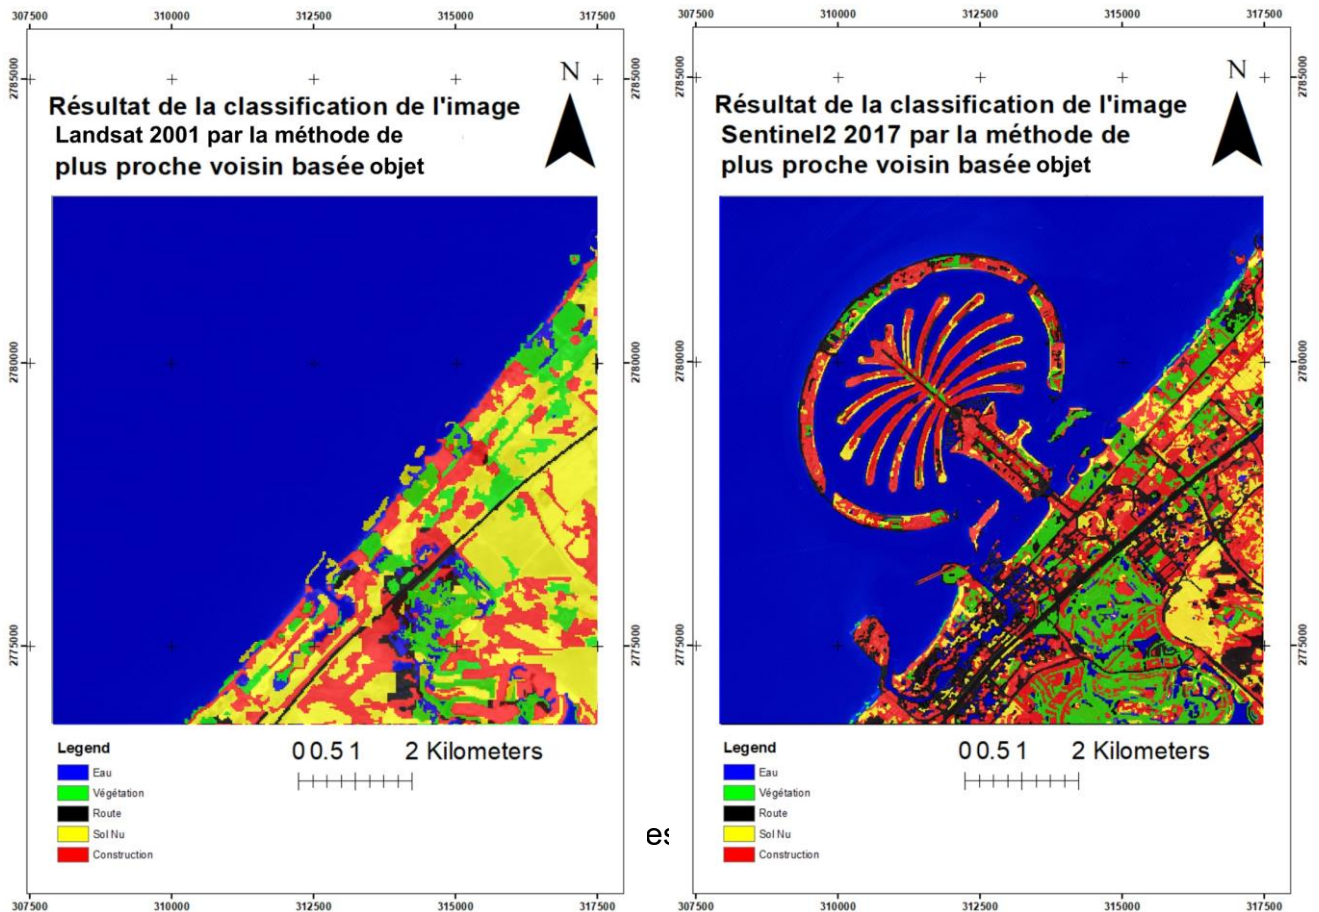


Figure 9 : Résultats de la classification par plus proche voisin basée objet

Arbre de décision

Dans cette méthode, on n'introduit pas les zones d'entraînement mais on pose des conditions sur les différentes classes pour avoir la classification finale.

Pour l'image de 2001 les conditions sont les suivantes :

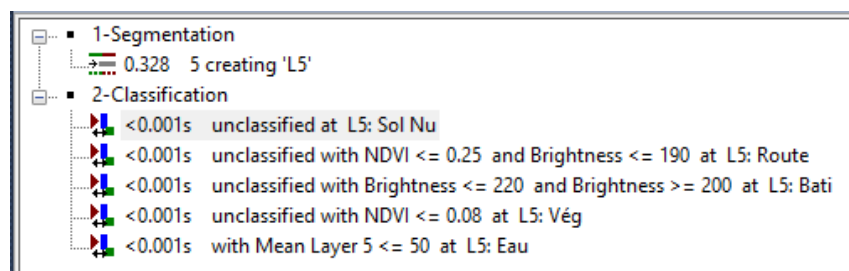


Figure 10 : Les conditions de l'image 2001

Alors que pour l'image 2017 :




Figure 11 : Les conditions de l'image 2017

On a eu les résultats suivants :

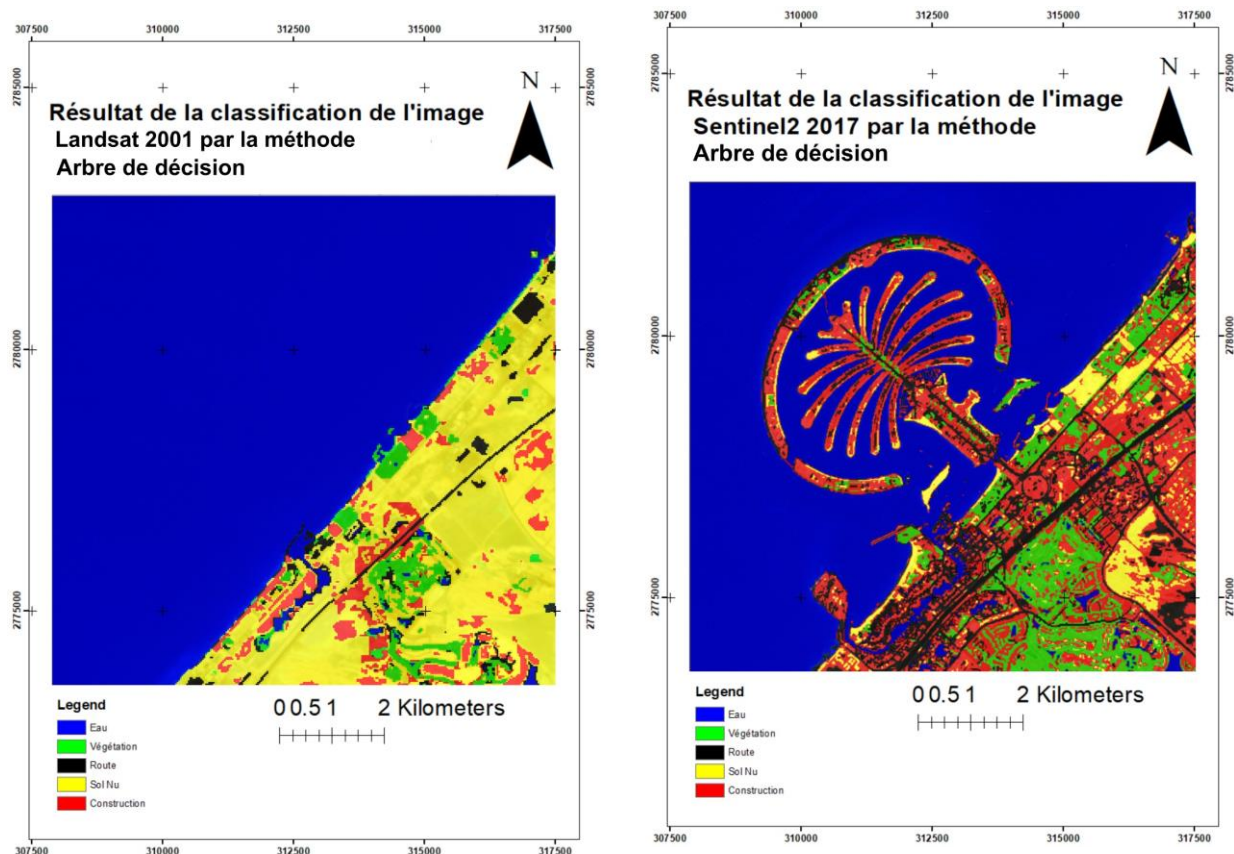


Figure 12 : Résultats par la méthode Arbre de décision

On peut constater qu'il reste encore des confusions entre les 3 classes suivantes: "Route", "Sol Nu" et "Bâti".

Système à base de règles: C'est presque la même chose que l'arbre de décision mais dans cette méthode on pose les conditions lors de définition de chaque classe.

Les règles des différentes classes:

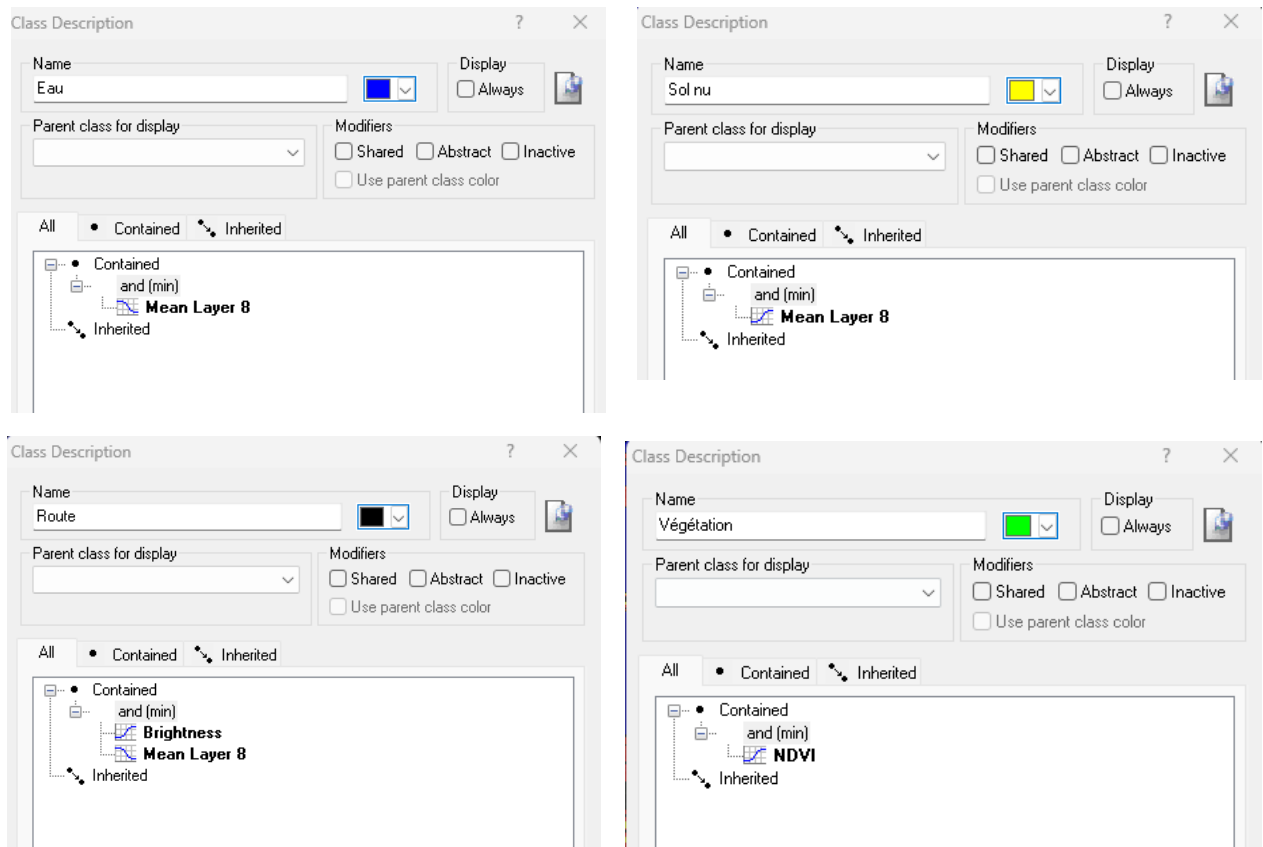


Figure 13 : Les conditions sur les classes

Ainsi on a obtenu les résultats suivants :

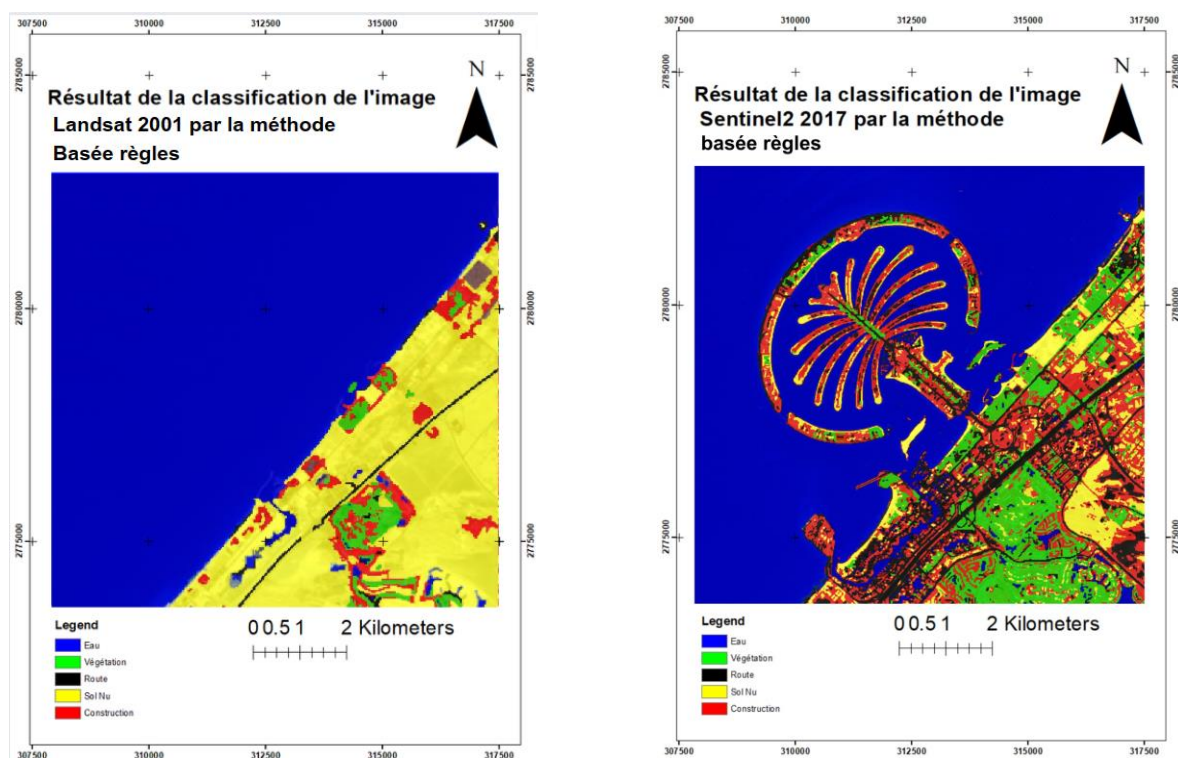


Figure 14 : Résultat de Système à base de règles

Analyse:

Visuellement, il est clair qu'au niveau de la classification 2001 il y a des confusions entre le sol nu et les constructions ceci du à la segmentation en premier lieu qui peut être plus petite considérons qu'il y a peu des constructions qui peuvent être remarquées et donc une segmentation avec un échelle plus petit est nécessaire pour améliorer notre classification Sinon pour 2017 on remarque que la classification est très solide vu qu'il y a peu de nuance entre la classification et ce qui est représenté sur l'image.

2.3. Classification par Random Forest :

Pour cette partie, on a utilisé la solution **Google Earth Engine**, c'est une plateforme basée sur le cloud qui permet le traitement à grande échelle d'images satellites pour détecter les changements, cartographier les tendances et quantifier les différences à la surface de la Terre.

En ce qui concerne le processus de classification, on a premièrement introduit les zones d'entraînement pour chaque classe, ensuite on s'est basé sur le code figurant dans le drive :

Résultats :

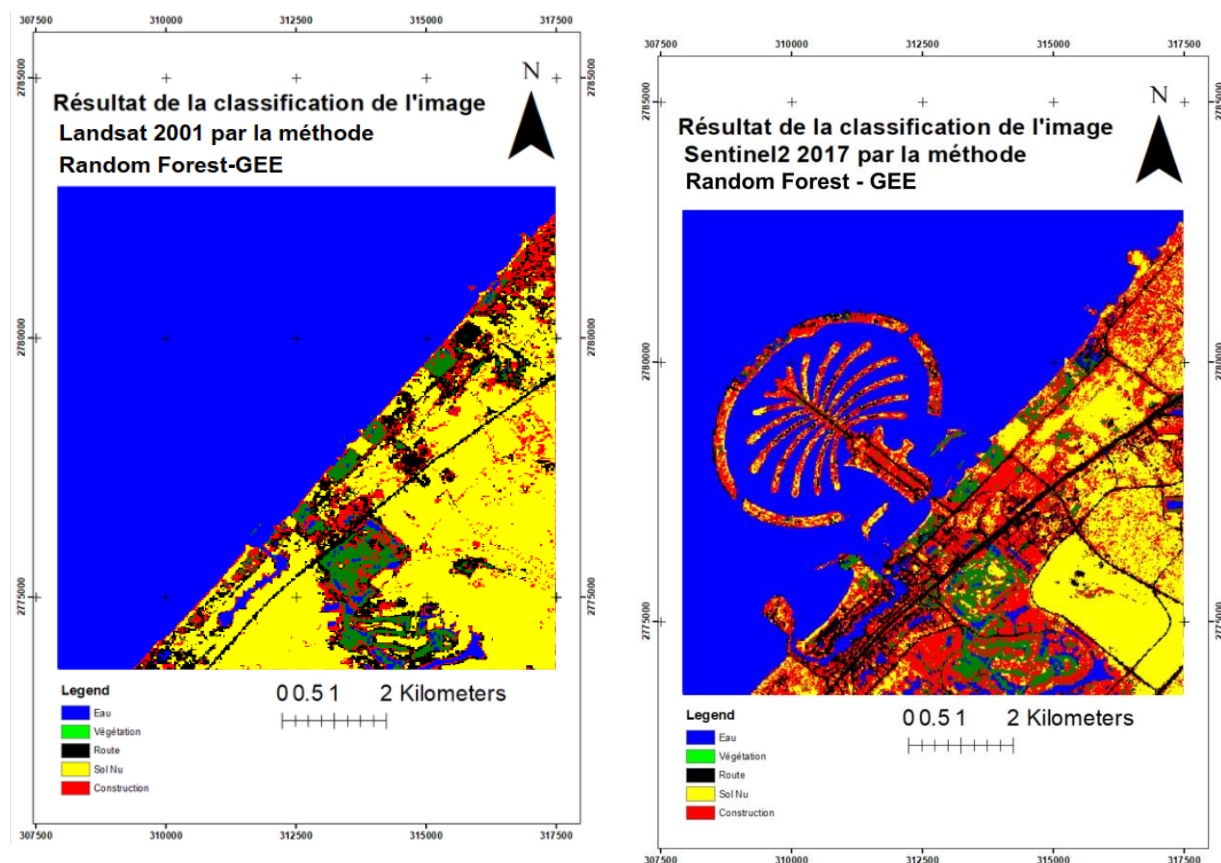


Figure 15 : Résultat de Système à base de règles

Analyse :

Avant de présenter notre analyse voici le lien **GEE** de notre travail :

“ <https://code.earthengine.google.com/cd6b2cdc44c34eea49e55f2e4cb5a036> ”

Pour cette méthode on a eu de bons résultats à partir du premier essai.

Au niveau de l'image de 2001 il y avait une petite confusion entre bâtiment et sol nu mais c'était pratiquement négligeable vu que cette confusion n'était pas apparente au niveau de l'image 2017

Pour l'image 2017 il y avait problème de classification de la route à l'extrémité de l'archipelle, mais visuellement c'était très bien réalisé.

Pour les matrices des confusions, on a divisé nos samples en 2 parties 70% classification et 30% pour validation

Validation error matrix 2017:

List (5 elements)

- 0: [30071,0,0,0,0]
- 1: [0,233,0,0,1]
- 2: [0,1,5033,0,5]
- 3: [0,0,4,455,5]
- 4: [0,4,18,3,400]

Validation overall accuracy 2017:

0.9988684348522066

Validation error matrix 2001:

List (5 elements)

- 0: [11677,0,0,0,0]
- 1: [1,93,1,0,3]
- 2: [0,4,188,0,14]
- 3: [1,0,0,732,0]
- 4: [0,0,0,0,3296]

Validation overall accuracy 2001:

0.9985009369144284

Figure 16 : Matrice de confusion Random Forest pour 2001 et 2017

2.4. Classification par réseau de neurones :

La classification des images par un réseau de neurones artificiels repose sur le principe suivant :

- Les pixels d'entraînement sont introduits l'un après l'autre ;
- Le réseau assimile progressivement leurs caractéristiques en ajustant ses paramètres internes ;
- La configuration des poids en fin d'étape d'apprentissage est utilisée pour classer le reste de l'image ;
- Chaque pixel est affecté à la sortie qui correspond à sa classe.


2.4.1. Logiciel utilisé : ENVI

ENVI (Environment for Visualizing Images) est un logiciel développé par la société Exelis Visual Information Solutions, maintenant connue sous le nom de Harris Geospatial Solutions. Il est largement utilisé dans le domaine de la télédétection et de l'analyse d'images satellitaires pour extraire des informations précieuses à partir d'images géospatiales, il peut servir pour l'analyse Spectrale, classification d'Images, extraction de Caractéristiques, analyse 3D , intégration avec d'autres Outils, traitement d'Images, support Multispectrale et Hyperspectrale.

Ce logiciel de traitement d'images facilite plusieurs tâches liées à la création, l'entraînement et la simulation des réseaux de neurones pour des fins de classification d'images.

2.4.2. Définition des régions d'intérêt

Les classes utilisées :



2.4.2.1. Image 2001



Figure 17 : Zones d'entraînement pour l'image de 2001

2.4.2.2. Image 2017




Figure 18 : Zones d'entraînement pour l'image de 2017

2.4.3. Choix des paramètres

Plusieurs paramètres ont été définis au cours de cet apprentissage. Ces paramètres sont liés au fonctionnement interne de l'algorithme de rétropropagation : le nombre de couches cachées, le taux d'apprentissage, le momentum, la fonction d'activation, le seuil d'arrêt et le nombre d'itérations.

-Le seuil de contribution à l'apprentissage (Training Threshold Contribution) : Ce paramètre détermine le niveau auquel une contribution spécifique est considérée comme pertinente ou significative pendant le processus d'apprentissage.

-Le taux d'apprentissage (Training rate) : permet de calculer les changements à apporter aux valeurs de poids après chaque itération. Sa valeur affecte considérablement la performance de l'algorithme d'apprentissage. Il varie entre 0 et 1.

-Le momentum (training momentum) : Il varie aussi de 0 à 1 et mesure l'effet d'une itération antérieure sur l'itération en cours (mise à jour actuelle des poids)

-Le seuil d'arrêt varie de 0 à 1 et **le nombre d'itérations** est défini par l'utilisateur.

-La fonction d'activation : souvent sigmoïde ou tangente hyperbolique, normalise les valeurs attribuées aux neurones de sorties. Elle intervient entre le niveau d'entrée et le niveau caché d'une part, et entre le niveau caché et le niveau de sortie d'autre part. L'apprentissage du réseau s'arrête lorsque l'erreur dépasse une valeur optimale établie à priori (seuil d'arrêt) ou lorsque le nombre d'itération est atteint.

2.4.3.1. Image 2001

- **Essai1:**

On fixe le nombre d'itérations à 1000 et on définit les paramètres suivants

Training Threshold Contribution	0.9000
Training Rate	0.2000
Training Momentum	0.9000
Training RMS Exit Criteria	0.0100

Figure 19 : Paramètres identifiés lors du 1er essai

On constate que dès la 25ème itération, la valeur de l'RMS d'entraînement n'oscille qu'entre 0.20 et 0.21, cela peut indiquer que le modèle a convergé et qu'entraîner davantage d'itérations n'est pas nécessaire. donc on peut se contenter de 30 itérations.

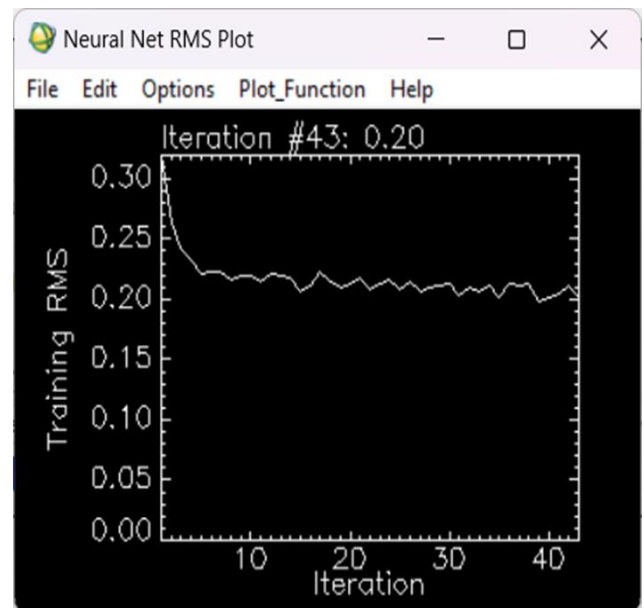


Figure 20 : Graphe représentant le RMS d'entraînement en fonction du nombre d'itérations

Le résultat de la classification :




Figure 21 : Résultats de la classification par réseau de neurones de l'image de 2001

Visuellement, on peut remarquer de fausses détections au niveau de la classe bati surtout sur la cote, et au niveau de la classe route qui se confond avec le sol.

En modifiant les ROIs

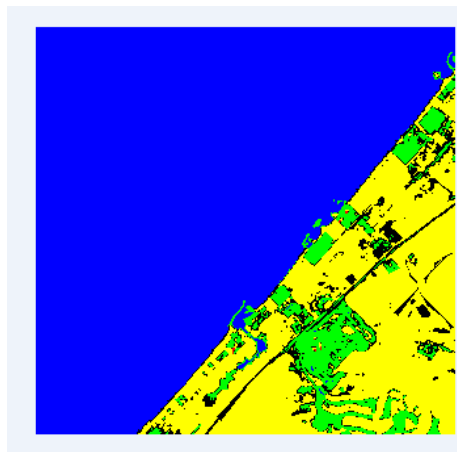


Figure 22 : Résultats de la classification par réseau de neurones de l'image de 2001 après modification de ROIs

On peut remarquer ainsi de fausses détections au niveau de la classe route, du bati et de la végétation.

- **Essai 2**

En utilisant les ROIs initiales avec un nombre d'itérations de 2000:

Training Threshold Contribution	0.9000
Training Rate	0.0100
Training Momentum	0.0000
Training RMS Exit Criteria	0.0100

Figure 24 : Paramètres identifiés lors du 2ème essai

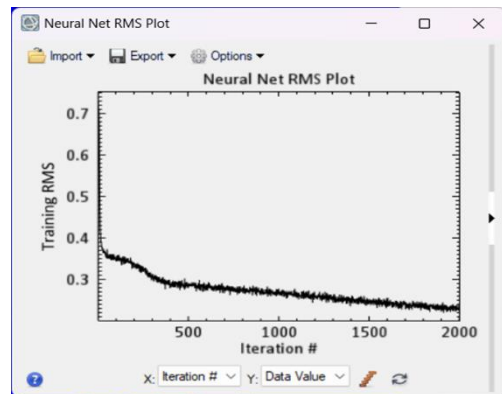


Figure 23 : Graphe représentant le RMS d'entraînement en fonction du nombre d'itérations




Figure 25 : Résultats de la classification par réseau de neurones de l'image de 2001 lors du 2ème essai

On remarque des confusions entre la classe sol et la classe route, ainsi que la classe bati.

- Essai 3

En utilisant les mêmes paramètres de l'essai 2, et on modifie les ROIs. On peut remarquer lors de l'entraînement que l'RMS se stabilise entre 0.27 et 0.28 dès la 50ème itération donc on fixe le nombre d'itérations sur 100 itérations




Figure 26 : Graphe représentant le RMS d'entrainement en fonction du nombre d'itérations




Figure 27 : Résultats de la classification par réseau de neurones de l'image de 2001 lors du 3ème essai

la qualité de la classification apparait falcilfiée, la classe route ne contient que de petits tronçons, la classe eau se confond avec le sol, la végétation et le bati ne sont pas très bien distingués

2.4.3.2. Image 2017

- Essai 1

On fixe le nombre des itérations à 1000 et on définit les paramètres suivants

Training Threshold Contribution	0.9000
Training Rate	0.2000
Training Momentum	0.9000
Training RMS Exit Criteria	0.1000

Figure 28 : Paramètres identifiés lors du 1er essai image 2017

On remarque que la valeur de RMS diminue progressivement, ceci montre que le modèle apprend à mieux s'adapter aux données d'entraînement, par contre la valeur ne se stabilise pas ceci indique qu'il se peut que le taux d'apprentissage est trop élevé.




Figure 29 : Graphe représentant le RMS d'entraînement en fonction du nombre d'itérations

Résultat :




Figure 30 : Résultats de la classification par réseau de neurones de l'image de 2017 lors du 1er essai

On remarque qu'il y a des confusions entre quelques éléments de route et du sol, ainsi que quelques éléments du sol sont classifiés comme bati, et d'autres éléments bati qui ont été considérés des éléments de route, ceci est peut-être dû à certaines ressemblances dans les caractéristiques spectrales ou à la insuffisance des données d'entraînement, il faut alors donner plus des zones d'entraînement pour affiner le modèle.

- Essai 2

Après ajout des ROI, on augmente on diminue le taux d'apprentissage et on donne la valeur 0 au momentum pour accélérer la convergence et réduire les oscillations et on diminue le RMS d'entraînement pour augmenter la précision de classification.

Training Threshold Contribution	0.9000
Training Rate	0.01000
Training Momentum	0
Training RMS Exit Criteria	0.01000

Figure 31 : Paramètres identifiés lors du 2ème essai image 2017

On remarque que la convergence est lente mais stable vers la valeur 0.15, par contre l'intervalle de l'erreur est augmenté et la valeur maximale est devenue 0.30, ceci est dû à la diminution du taux d'apprentissage et l'augmentation des données d'entraînement




Figure 32 : Graphe représentant le RMS d'entrainement en fonction du nombre d'itérations Essai2

Résultat




Figure 33 : Résultats de la classification par réseau de neurones de l'image de 2017 lors du 2ème essai

On remarque que la classification est améliorée, au niveau des classes eau, végétation et routes, par contre quelques éléments bâtis ont été classés dans la classe route, ainsi que des confusions entre le sol et le bâti. Peut-être qu'il faut agir sur le momentum et la vérification des zones d'entraînement de la classe route.

- Essai 3

En supprimant et ajoutant quelques échantillons au niveau de la classe route, on augmente le momentum à 0.5 et on garde les autres paramètres, On remarque que les oscillations ne présente pas beaucoup de bruit, et le graphe converge vers une valeur stable de 0.15 dans l'itération 100




Figure 34 : Graphe représentant le RMS d'entrainement en fonction du nombre d'itérations Essai2

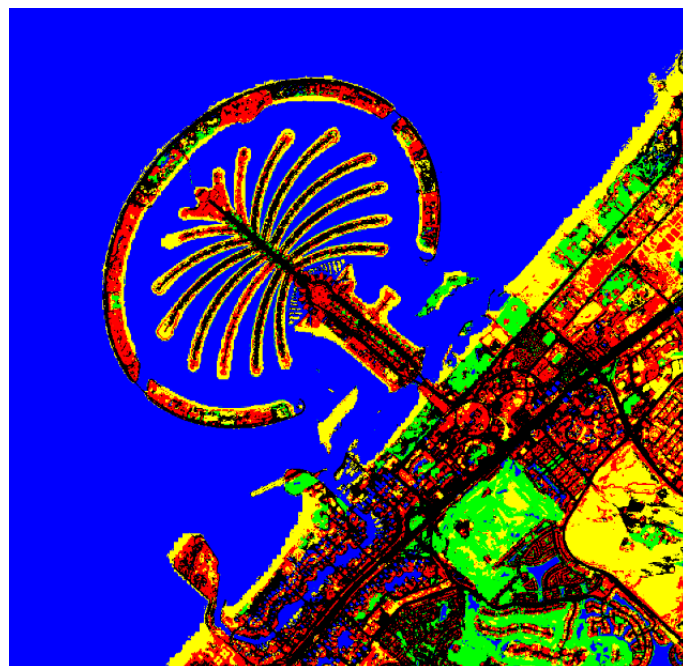


Figure 35 : Résultats de la classification par réseau de neurones de l'image de 2017 lors du 3ème essai

On remarque que les éléments sont beaucoup mieux classifiés en leurs classes correspondantes, sauf quelques confusions entre le sol et le bati , ceci est peut être à cause de la résolution de l'image.

Donc on peut conclure que l'augmentation du momentum n'affecte pas trop la précision.

2.4.4. Matrice de confusion


2.4.4.1. Image 2001

- Essai 1

essai	data (1).json	X_train.npy	X_train.npy	README	test
Fichier	Modifier	Affichage			
Confusion Matrix: C:\Users\wijda\AppData\Local\Temp\cnn					
Overall Accuracy = (10943/11200) 97.7054%					
Kappa Coefficient = 0.9562					
	Ground Truth (Pixels)				
Class	Eau	Route	Sol	Veg	Bati
Unclassified	0	0	0	0	0
Eau	7017	0	0	0	27
Route	0	271	9	13	1
Sol	0	61	2987	7	7
Veg	0	1	1	533	3
Bati	182	0	3	22	135
Total	7119	333	3000	575	173
	Ground Truth (Pixels)				
Class	Total				
Unclassified	0				
Eau	7044				
Route	294				
Sol	3062				
Veg	538				
Bati	262				
Total	11200				
	Ground Truth (Percent)				
Class	Eau	Route	Sol	Veg	Bati
Unclassified	0.00	0.00	0.00	0.00	0.00
Eau	98.57	0.00	0.00	0.00	15.61
Route	0.00	81.38	0.30	2.26	0.58
Sol	0.00	18.32	99.57	1.22	4.05
Veg	0.00	0.30	0.03	92.70	1.73
Bati	1.43	0.00	0.10	2.83	78.83
Total	100.00	100.00	100.00	100.00	100.00
	Ground Truth (Percent)				
Class	Total				
Unclassified	0.00				
Eau	98.57				
Route	2.68				
Sol	27.33				
Veg	4.79				
Bati	2.33				
Total	100.00				

Figure 36 : Matrice de confusion 1er essai

On peut remarquer de très grandes confusions entre "l'eau" et "le bati", ainsi que "la route" et "le sol"





Après changement de ROIs

essaie	data (1).geojson	X_train.npy	X_train.npy	README	test
Fichier	Modifier	Affichage			
Confusion Matrix: C:\Users\wijda\Downloads\Données\cm_2001					
Overall Accuracy = (17200/17672) 97.3800%					
Kappa Coefficient = 0.9263					
Ground Truth (Pixels)					
Class	Route	Veg	Sol	Eau	Bati
Unclassified	0	0	0	0	0
Route [Black]	89	26	62	0	3
Veg [Green] 5	25	470	0	0	2
Sol [Yellow]	317	12	2796	0	10
Eau [Blue] 13	0	6	0	13854	0
Bati [Red] 15	0	0	0	0	0
Total	431	514	2858	13854	15
Ground Truth (Pixels)					
Class	Total				
Unclassified	0				
Route [Black]	189				
Veg [Green] 5	497				
Sol [Yellow]	3135				
Eau [Blue] 13	13860				
Bati [Red] 15	0				
Total	17672				
Ground Truth (Percent)					
Class	Route	Veg	Sol	Eau	Bati
Unclassified	0.00	0.00	0.00	0.00	0.00
Route [Black]	20.65	5.06	2.17	0.00	20.00
Veg [Green] 5	5.80	91.44	0.00	0.00	13.33
Sol [Yellow]	73.55	2.33	97.83	0.00	66.67
Eau [Blue] 13	0.00	1.17	0.00	100.00	0.00
Bati [Red] 15	0.00	0.00	0.00	0.00	0.00
Total	100.00	100.00	100.00	100.00	100.00
Ground Truth (Percent)					
Class	Total				

Figure 37 : Matrice de confusion 1er essai après changement

On peut remarquer que que la confusion se distingue surtout au niveau de la “route” avec le “sol” et la végétation, ainsi qu’au niveau du “Bati” avec le “Sol”.




- Essai 2

essaie	data (1).geojson	X_train.npy	X_train.npy	README	test
Fichier	Modifier	Affichage			
Confusion Matrix: C:\Users\wijda\AppData\Local\Temp\cn2					
Overall Accuracy = (10832/11200) 96.7143%					
Kappa Coefficient = 0.9362					
Ground Truth (Pixels)					
Class	Eau	Route	Sol	Veg	Bati
Unclassified	0	0	0	0	0
Eau	7099	0	0	1	48
Route	5	198	3	19	15
Sol	0	131	2993	13	33
Veg	15	4	4	542	77
Bati	0	0	0	0	0
Total	7119	333	3000	575	173
Ground Truth (Pixels)					
Class	Total				
Unclassified	0				
Eau	7148				
Route	240				
Sol	3170				
Veg	642				
Bati	0				
Total	11200				
Ground Truth (Percent)					
Class	Eau	Route	Sol	Veg	Bati
Unclassified	0.00	0.00	0.00	0.00	0.00
Eau	99.72	0.00	0.00	0.17	27.75
Route	0.07	59.46	0.10	3.30	8.67
Sol	0.00	39.34	99.77	2.26	19.08
Veg	0.21	1.20	0.13	94.26	44.51
Bati	0.00	0.00	0.00	0.00	0.00
Total	100.00	100.00	100.00	100.00	100.00
Ground Truth (Percent)					
Class	Total				

Figure 38 : Matrice de confusion 2ème essai

La confusion se distingue clairement entre la class “route” et “sol” ainsi que pour le “bati” qui connait une detection tout à fait fafcifiée (0 detection pour le bati même pour les ROIs).



- Essai 3

File

Confusion Matrix: C:\Users\wijda\Downloads\Données\cnrl_2001

Overall Accuracy = (16712/17672) 94.5677%

Kappa Coefficient = 0.8426

Class	Ground Truth (Pixels)		Sol	Eau	Bati
	Route	Veg			
Unclassified	0	0	0	0	0
Route [Black]	0	0	0	0	0
Veg [Green] 5	0	0	0	0	0
Sol [Yellow]	431	361	2858	0	15
Eau [Blue] 13	0	153	0	13854	0
Bati [Red] 15	0	0	0	0	0
Total	431	514	2858	13854	15

Class	Ground Truth (Pixels)				
	Total				
Unclassified	0				
Route [Black]	0				
Veg [Green] 5	0				
Sol [Yellow]	3665				
Eau [Blue] 13	14097				
Bati [Red] 15	0				
Total	17672				

Class	Ground Truth (Percent)		Sol	Eau	Bati
	Route	Veg			
Unclassified	0.00	0.00	0.00	0.00	0.00
Route [Black]	0.00	0.00	0.00	0.00	0.00
Veg [Green] 5	0.00	0.00	0.00	0.00	0.00
Sol [Yellow]	100.00	70.23	100.00	0.00	100.00
Eau [Blue] 13	0.00	29.77	0.00	100.00	0.00
Bati [Red] 15	0.00	0.00	0.00	0.00	0.00
Total	100.00	100.00	100.00	100.00	100.00

Class	Ground Truth (Percent)				
	Total				
Unclassified	0.00				
Route [Black]	0.00				
Veg [Green] 5	0.00				
Sol [Yellow]	20.74				
Eau [Blue] 13	79.26				
Bati [Red] 15	0.00				
Total	100.00				

Class	Commission (Percent)	Omission (Percent)	Commission (Pixels)	Omission (Pixels)
Route [Black]	0.00	100.00	0/0	431/431
Veg [Green] 5	0.00	100.00	0/0	514/514
Sol [Yellow]	22.02	0.00	807/3665	0/2858
Eau [Blue] 13	1.09	0.00	153/14097	0/13854
Bati [Red] 15	0.00	100.00	0/0	15/15

Figure 39 : Matrice de confusion 3ème essai

Les confusions sont très marquées dans ce cas au niveau de toutes les classes à l'exception du “Sol” et de “l'eau”.

- pour le coefficient Kappa le plus favorable concerne le premier essai (Kappa = 0.9562 suivi par le deuxième essai avec un coefficient Kappa égal à 0.9263)

2.4.4.2. Image 2017

- Essai 1

Confusion Matrix: I:\S5\RN\classif1\classif1'

Overall Accuracy = (96749/98876) 97.8488%

Kappa Coefficient = 0.9019

		Ground Truth (Pixels)				
Class		Eau	Veg	Sol	Bati	Route
Unclassified		0	0	0	0	0
Eau [Blue] 86		87080	48	4	4	0
Veg [Green] 2		58	2754	0	1	39
Sol [Yellow]		0	0	3062	64	2
Bati [Red] 17		0	16	617	736	24
Route [Black]		14	19	1164	53	3117
Total		87152	2837	4847	858	3182

		Ground Truth (Pixels)				
Class		Total				
Unclassified		0				
Eau [Blue] 86		87136				
Veg [Green] 2		2852				
Sol [Yellow]		3128				
Bati [Red] 17		1393				
Route [Black]		4367				
Total		98876				


		Ground Truth (Percent)				
Class		Eau	Veg	Sol	Bati	Route
Unclassified		0.00	0.00	0.00	0.00	0.00
Eau [Blue] 86		99.92	1.69	0.08	0.47	0.00
Veg [Green] 2		0.07	97.07	0.00	0.12	1.23
Sol [Yellow]		0.00	0.00	63.17	7.46	0.06
Bati [Red] 17		0.00	0.56	12.73	85.78	0.75
Route [Black]		0.02	0.67	24.01	6.18	97.96
Total		100.00	100.00	100.00	100.00	100.00

		Ground Truth (Percent)				
Class		Total				
Unclassified		0.00				
Eau [Blue] 86		88.13				
Veg [Green] 2		2.88				
Sol [Yellow]		3.16				
Bati [Red] 17		1.41				
Route [Black]		4.42				
Total		100.00				

Figure 40 : Matrice de confusion 1er essai

La matrice confirme la confision entre la classe “bati” et “sol” , entre “sol” et “route” , ainsi que “bati” et route”


Bati et route



Bati et sol



Sol et route




- Essai 2

Confusion Matrix: I:\S5\RN\Classif4\Classif4						
Overall Accuracy = (98063/98876) 99.1778%						
Kappa Coefficient = 0.9622						
Ground Truth (Pixels)						
Class	Eau	Veg	Sol	Bati	Route	
Unclassified	0	0	0	0	0	
Eau [Blue] 89	87099	147	66	0	0	
Veg [Green] 3	44	2666	0	2	23	
Sol [Yellow]	0	6	4707	315	44	
Bati [Red] 30	0	1	74	496	20	
Route [Black]	9	17	0	45	3095	
Total	87152	2837	4847	858	3182	
Ground Truth (Pixels)						
Class	Total					
Unclassified	0					
Eau [Blue] 89	87312					
Veg [Green] 3	2735					
Sol [Yellow]	5072					
Bati [Red] 30	591					
Route [Black]	3166					
Total	98876					
Ground Truth (Percent)						
Class	Eau	Veg	Sol	Bati	Route	
Unclassified	0.00	0.00	0.00	0.00	0.00	
Eau [Blue] 89	99.94	5.18	1.36	0.00	0.00	
Veg [Green] 3	0.05	93.97	0.00	0.23	0.72	
Sol [Yellow]	0.00	0.21	97.11	36.71	1.38	
Bati [Red] 30	0.00	0.04	1.53	57.81	0.63	
Route [Black]	0.01	0.60	0.00	5.24	97.27	
Total	100.00	100.00	100.00	100.00	100.00	
Ground Truth (Percent)						
Class	Total					
Unclassified	0.00					
Eau [Blue] 89	88.30					
Veg [Green] 3	2.77					
Sol [Yellow]	5.13					
Bati [Red] 30	0.60					
Route [Black]	3.20					
Total	100.00					

Figure 41 : Matrice de confusion 2ème essai

Le résultat est beaucoup amélioré, mais il reste toujours une confusion entre le “bati” et le “sol”




- Essai 3 :

Confusion Matrix: I:\S5\RN\Classif3\Classif3					
Overall Accuracy = (98327/98876) 99.4448%					
Kappa Coefficient = 0.9746					
Ground Truth (Pixels)					
Class	Eau	Veg	Sol	Bati	Route
Unclassified	0	0	0	0	0
Eau [Blue] 88	87118	87	2	4	0
Veg [Green] 3	29	2736	0	9	12
Sol [Yellow]	2	9	4751	220	0
Bati [Red] 27	0	0	73	568	16
Route [Black]	3	5	21	57	3154
Total	87152	2837	4847	858	3182
Ground Truth (Pixels)					
Class	Total				
Unclassified	0				
Eau [Blue] 88	87211				
Veg [Green] 3	2786				
Sol [Yellow]	4982				
Bati [Red] 27	657				
Route [Black]	3240				
Total	98876				
Ground Truth (Percent)					
Class	Eau	Veg	Sol	Bati	Route
Unclassified	0.00	0.00	0.00	0.00	0.00
Eau [Blue] 88	99.96	3.07	0.04	0.47	0.00
Veg [Green] 3	0.03	96.44	0.00	1.05	0.38
Sol [Yellow]	0.00	0.32	98.02	25.64	0.00
Bati [Red] 27	0.00	0.00	1.51	66.20	0.50
Route [Black]	0.00	0.18	0.43	6.64	99.12
Total	100.00	100.00	100.00	100.00	100.00
Ground Truth (Percent)					
Class	Total				
Unclassified	0.00				
Eau [Blue] 88	88.20				
Veg [Green] 3	2.82				
Sol [Yellow]	5.04				
Bati [Red] 27	0.66				
Route [Black]	3.28				
Total	100.00				

Figure 42 : Matrice de confusion 3ème essai

Il reste toujours des confusions entre le Bati et le Sol mais elle est moins pointu




VII. Comparaison entre les différentes méthodes:

1. Les méthodes basées pixel :


Dans ce travail, on s'est basé sur 2 méthodes basées pixel: "Plus proches voisins" et "Random Forest".

Pour la première méthode, on a les résultats suivants:

En analysant l'image classifié de 2001, on remarque que:



Une confusion entre les classes "Sol Nu" et "Route" dans plusieurs endroit



Mauvaise classification dans la partie centrale de notre
Confusion entre les différentes classes

En ce qui concerne la deuxième image:


La classification est meilleure que celle de 2001 mais il existe aussi des zones de fausse détection:




Les zones noires doivent normalement être dans la classe "Bâti" alors que le résultat donne la classe "Route"

Passant maintenant à la deuxième méthode "Random Forest":

Pour la première image on a:



Pour la deuxième image on a:



Encore des fausses détections de la classe "Route", mais elles ne sont pas nombreuses en les comparant avec la méthode plus proches voisins.


D'après tout ce qui est cité dans la partie Méthode de classification et la partie Comparaison, on peut constater que la meilleure classification basée pixel est celle faite par la méthode "Random Forest" en utilisant GEE.

2. Les méthodes basées objet :


Les méthodes qui seront comparées dans cette partie sont : Plus Proches Voisins, Arbre de décision et Système à base de règles

Plus Proches Voisins:

Pour l'année 2001 on a:




Des confusions entre la classe "Route" et les classes "Bâti"-"Sol Nu".



Les routes ont été considérées comme sol nu.


Alors que pour l'image 2017:




Même remarque: des confusions entre les classes "Route" "Bâti" et "Sol Nu"

Arbre de décision:

Image 2001:



Détection des routes comme sol nu



Détection des sols nus et des bâtiment comme routes

Image 2017:

Les mêmes problèmes que les autres classifications, on a des confusion surtout entre les classes "Route" "Sol Nu" et "Bâti". Alors que pour l'eau et la végétation sont bien classifiés.

Système à base règles:

On peut dire que les mêmes fausses détections se répètent dans ces trois méthodes de classifications basées objet ,pour les deux images. Il reste toujours la confusion entre les trois classes citées.

Conclusion:

Comme les 3 méthodes donnent les mêmes résultats et puisqu'on a pas des métriques sur lesquels on va se baser pour choisir une meilleure classification, on va pas prendre en considération ces méthodes et pour le choix final, on va se baser juste sur les méthodes basée pixel et le réseau de neurones.

3. Réseau de neurones :

3.1. Image de 2001

D'après la comparaison des métriques des différents essais précédents, sans négliger la comparaison visuelle, on peut favoriser le résultat du deuxième essai.




Figure 43 : Résultat de classification pour l'image de 2001

C'est vrai que d'après les matrices de confusion et la comparaison des coefficients Kappa, apparaît que le premier essai est le plus value mais visuellement, on peut distinguer que la classe "Bâti" est clairement faussement détectée, ainsi que pour les autres essais.

Le résultat du deuxième essai apparaît acceptable par rapport aux autres même s'il existe encore d'omissions au niveau de la classe "route" et de la classe "Bâti", ainsi que des erreurs de commission au niveau de la classe "Sol".

3.2. Image de 2017

En comparant le résultat de classification entre les 3 essai, au niveau de visualisation ainsi que le graphe de RMS et la matrice de confusion, le 3ème essai donne le meilleur résultat

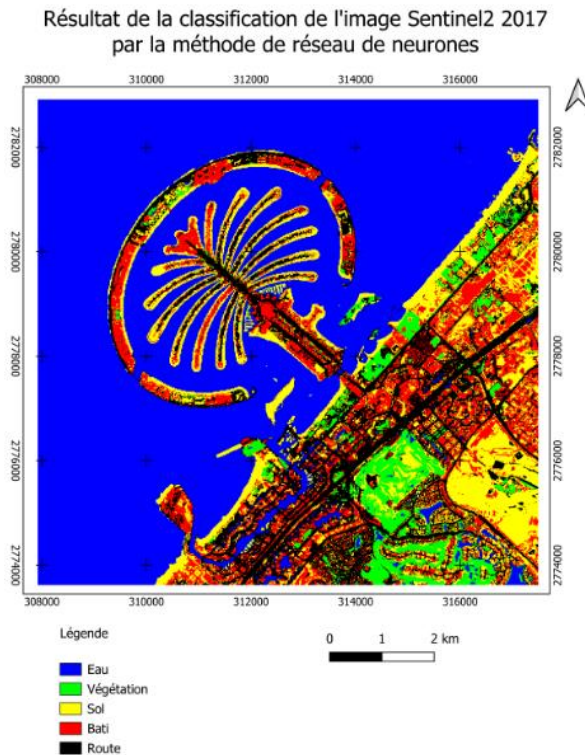


Figure 44 : Résultat de classification pour l'image de 2017 par RN

Le résultat du premier essai présente beaucoup de confusion entre les classe visuellement et au niveau de la matrice de confusion, alors que l'essai 2 et 3 les confusion ne sont pas assez remarquable sauf au niveau de la classe bati avec le sol qui est plus moins dans l'essai 3, ainsi que ce résultat adopté a un coefficient kappa est de 97%.

Ceci est grace à un taux d'apprentissage qui n'est pas trop élevé, et un nombre d'itération qui permet une stabilité de modèle, et un training RMS qui améliore la précision de classification.

Conclusion : les résultats de classification obtenus par réseaux de neurones sont plus ou moins favorables mais il reste encore des fausses détection qui apparaissent non tolérables surtout au niveau du bâti qui est notre fin d'étude.

3.3. Choix final:

Comme les résultats sont presque tous les mêmes, et puisqu'on n'a pas pu avoir les matrices de confusions et les coefficients Kappa de certaines méthodes, on a pris en considération les méthodes dont on se dispose des métriques et on a constaté que les classifications établies par GEE sont les meilleures en les comparant avec les autres méthodes.

4. Détection du changement :

Afin de détecter le changement entre les 2 années étudiées, on a pris les 2 images classifiées et , en utilisant GEE, on s'est basé sur le code suivant pour obtenir le résultat souhaité:

```
// Subtract the classified images for 2001 and 2017
var subtracted = classified2017.subtract(classified2001);

// Define the color palette
var palette = [ 'white', 'red'];

// Display the subtracted image with the specified color palette
Map.addLayer(subtracted,
  {min: 0, max: 1, palette: palette},
  'Change Detection (white: unchange, Red: added)');
```

Le principe général est :

- Faire une soustraction pixel par pixel entre les 2 images classifiées
- Choisir la palette de couleur afin de représenter les zones existantes en blanc et les zones modifiées ou nouvellement créées en rouge.

Cela nous donne le résultat suivant:

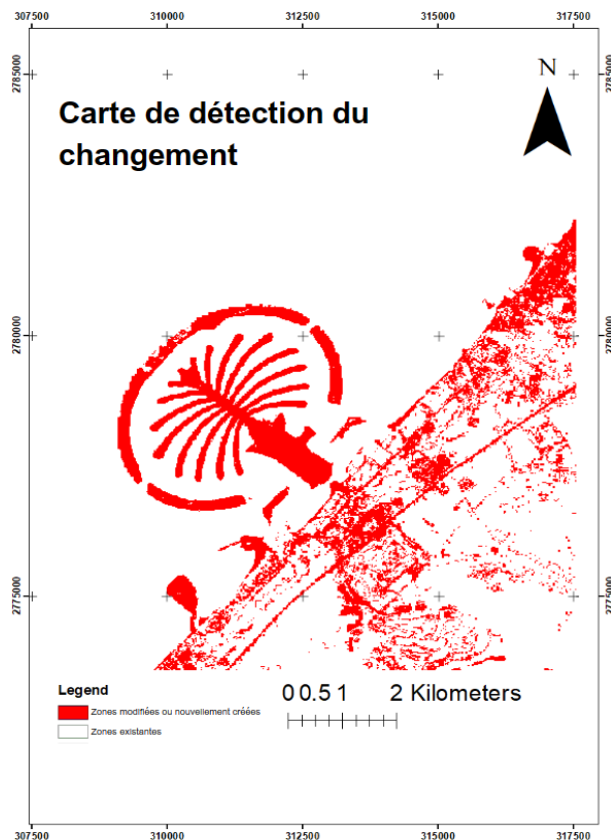


Figure 45 : Carte de détection du changement

5. Présentation du site web :

Pour présenter nos résultats de manière plus organisée, on a opté pour réaliser un site web dans lequel on a présenté notre thématique, présenter les différentes méthodes de classification qu'on a réalisé, on a même ajouté une partie pour les résultats finaux c'est à dire les classifications qu'on a jugé les meilleures avec la carte de détection du changement.

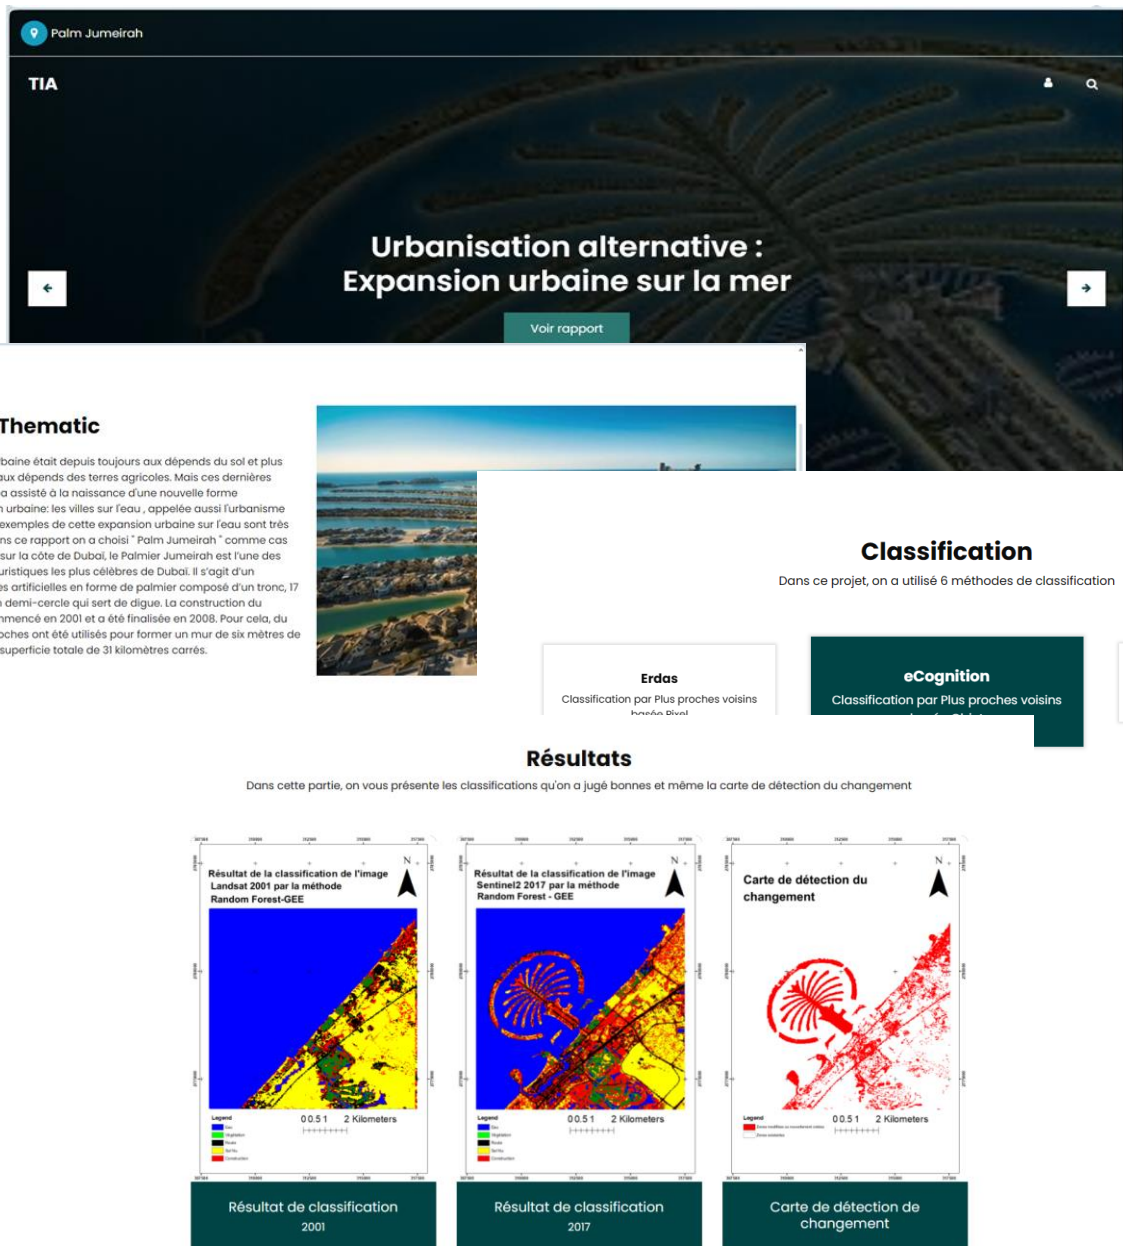


Figure 46 : Site Web

6. Conclusion :

Certes les objectifs de ce projet étaient d'appliquer des méthodes de traitement d'images avancées et les comparer en se basant sur plusieurs facteurs , d'analyser les changements qui résultent lors de l'expansion urbaine sur la mer de "Palm Jumeirah" entre les années 2001 et 2017.

Mais aussi pour présenter une solution qui sera pratique pour le cas de l'expansion de la ville de Rabat.

Comme on sait bien, la capitale du Maroc est limitée du côté nord par la ville de Salé, dans l'est on trouve la vallée Akrache et dans le sud on a la ceinture verte:



Figure 47 : Les limites de la zone de Rabat

Comme la population de Rabat ne cesse d'augmenter, et puisque les différentes zones dédiées à l'habitat sont déjà bâties, on peut penser à cette solution c'est à dire l'urbanisme alternatif sur l'océan atlantique qui va sûrement être une réponse efficace puisqu'on peut même se bénéficier de son côté touristique si cette partie de la ville sera sous une forme particulière.

RÉFÉRENCES :

[1] Support du cours "Traitement d'image avancé" (Pr. Imane Sebari)

[2] Classification supervisée d'images satellites — Documentation Briques de Géomatique 0.1 (briques-de-geomatique.readthedocs.io) (Paul Passy)

[3] Qu'est-ce qu'un arbre de décisions | IBM

[4] FORET D'ARBRES ALEATOIRES ET CLASSIFICATION D'IMAGES SATELLITES :
RELATION ENTRE LA PRECISION DU MODELE D'ENTRAINEMENT ET LA PRECISION
GLOBALE DE LA CLASSIFICATION (Aurélien N.G. Matsaguim¹ , Emmanuel D. Tiomo)

[5] L'apport de l'analyse de texture et des réseaux de neurones dans la cartographie de
l'utilisation des sols en milieu urbain (cas de la ville Sherbrooke)

[6] LES RESEAUX DE NEURONES ARTIFICIELS, INTRODUCTION AU
CONNEXIONNISME (hal.science) (Calude TOUZET Juillet 1992)

[7] Exploitation du logiciel eCognition pour la classification assistée par ordinateur
BRGM/RP-52120-FR janvier 2003

[8] Cartographie de l'occupation de sol des Hauts Plateaux de l'Ouest Cameroun par réseaux
de neurones appliqués à une image LANDSAT 8 OLI